1 2  9 0

FACULDADE DE CIÊNCIAS E TECNOLOGIA
UNIVERSIDADE D COIMBRA

Aprendizagem Computacional

Assignment 1

OCR – Optical Character Recognition

Professor: António Dourado Pereira Correia

Grupo: 1

Diogo Alexandre Santos Rosário nº 2023185395

Arthur Francisco Navickas Itacarambi nº2020115569

1 2 9 0
FACULDADE DE CIÊNCIAS E TECNOLOGIA
UNIVERSIDADE D COIMBRA

1. Introdução

Este relatório é o resultado de um trabalho proposto no âmbito da disciplina de Aprendizagem Computacional.

Apresentamos neste relatório uma visão periférica do problema em estudo *OCR - Optical Character Recognition*. Utilizando ferramentas de *machine learning*, disponibilizadas pelo *matlab* (aplicação externa), iremos tentar formular modelos de redes neuronais que consigam reconhecer os algarismos de 0-9 escritos a mão.

Nos próximos capítulos será discutido o passo-a-passo que os autores seguiram para chegar aos presentes resultados, o que esses resultados representam e o que podemos concluir sobre eles.

1 2 9 0
FACULDADE DE CIÊNCIAS E TECNOLOGIA
UNIVERSIDADE D
COIMBRA

2. *Dataset's*

O *dataset* de treino e de teste foram criados utilizando a aplicação *mpaper* como instruído:

"A) to generate, from a grid five-by-ten opened when it is runed, where the user draws manualy digits 0 to 9. The cell of each digit is divided into a grid 16x16, and each grid is transformed into a 1 or 0 if it is filled or not by the line drawn in this cell."

Para o dataset de treino, foi desenhado pelos autores deste relatório, 34 tabelas de 50 números. O resultado disso foi uma matriz com 1700 números e cada uma possuindo 256 atributos. Essa mesma matriz foi usada para treinar todos os modelos apresentados neste relatório.

Para os *dataset's* de teste, foram desenhadas outras 3 tabelas de 50 números. Ou seja, foram criados três testes diferentes.

Para criar o *target* do *dataset* usamos um programa autoral "createTarget.m", este programa gerou o arquivo "Target.mat" que também foi usado em todos os modelos apresentados neste relatório. O *target* consiste em um vetor com 10 posições, onde, todas as posições possuem o valor de 0, menos uma, a que possui o valor 1 e representa o valor correto (e cada vetor representa 1 único número apenas). Ou seja, o ficheiro "*Target.mat*" é uma matriz de 10 linhas com 1700 colunas.

No início do trabalho foi-nos disponibilizada uma matriz "*PerfectArial.mat*" utilizada para treinar os modelos com filtro (*Perceptron*, *Memória Associativa*). Essa matriz, da mesma forma que as feitas no *dataset* de treino e de teste, possui 256 atributos. Esta matriz possui informação de como seria cada um dos algarismos de 0 a 9 feitos perfeitamente. Esta matriz, também teve de ser adaptada para possuir 1700 números ao invés de 10.

O leitor poderá observar os resultados dos testes dos modelos na quarta secção deste relatório.

1 2 9 0
FACULDADE DE CIÊNCIAS E TECNOLOGIA
UNIVERSIDADE D COIMBRA

3. Treino

Neste projeto foram criados vários classificadores diferentes no entanto, estes distinguem-se em dois grandes grupos:

1. Grupo de classificadores de uma camada **com filtro,** em que este usa a *memória associativa* ou o *perceptron*.
2. Grupo de classificadores **sem filtro**, que podem possuir uma ou duas camadas.

Para além disso, para cada classificador treinado, foi dado o *dataset* de 1700 números.

Para o treino de cada classificador, seja ele de uma camada ou duas, foram usadas diferentes funções de ativação, nomeadamente: *purelin* (linear), *hardlim* (binária) e *logsig* (sigmóide).

Parâmetros utilizados no treino dos classificadores de uma ou duas camadas que usam as funções de ativação *Linear* e *Sigmoidal* :

- Função de treino (*trainFcn*) = *trainlm (Levenberg-Marquardt)*
- Número máximo de *epochs* = 1000;
- Gradiente = 1e-6;
- *Performance* = 1e-6;
- *Validation checks* = 6;

Parâmetros utilizados no treino dos classificadores que usam a função de ativação *Hardlim*:

- Função de treino (*trainFcn*) = *trainc*;
- Função de adaptação (*adaptFcn*) = *learnp*
- Número máximo de *epochs* = 1000;

Nota : Os modelos que contém duas camadas, foi definido o uso de 10 neurónios na camada escondida (*Hidden layer*). Para o caso dos filtros (*Perceptron* e *Memória Associativa*) foi dado o *dataset* de treino e também a matriz com os números desenhados perfeitamente, que neste caso seria o *target*.

1 2 9 0
FACULDADE DE CIÊNCIAS E TECNOLOGIA
UNIVERSIDADE D COIMBRA

4. Resultados

Neste capítulo, apresentamos os resultados obtidos a partir dos modelos treinados, destacando as funções de ativações utilizadas em cada um. Foram realizados quatro tipos de testes distintos, sendo estes: Teste A (256x50), Teste B(256x50), Teste C (256x50) e o conjunto de dados que foi usado para treinar todos os modelos, P(256x1700).

Nas próximas figuras conseguimos ver o Teste A, B e C.

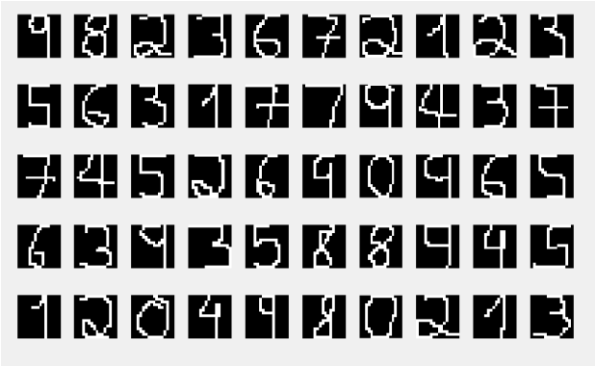

Figura 1 – Representação do teste A

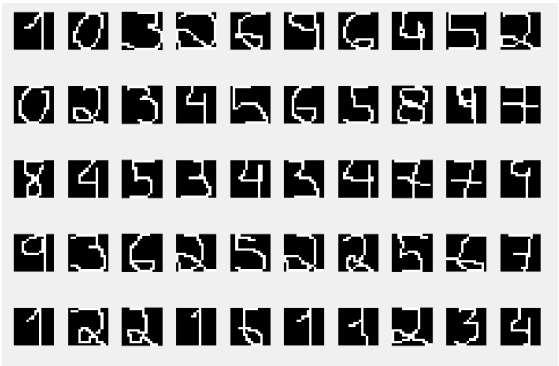

Figura 2 – Representação do teste B

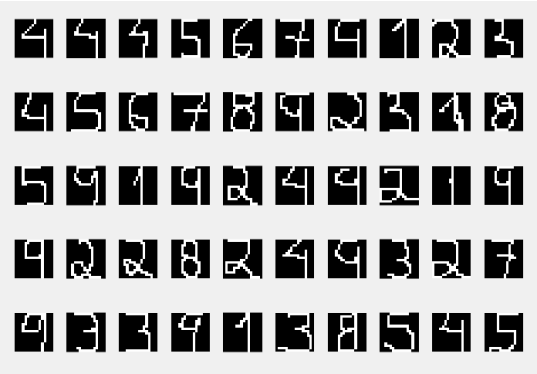

Figura 3 – Representação do teste C

4.1 Memória Associativa + Classificador de uma camada

	Purelin	Hardlim	Logsig
Treino	21.24%	19.53%	27.18%
Teste A	18.00%	16.00%	28.00%
Teste B	14.00%	18.00%	28.00%
Teste C	20.00%	18.00%	32.00%
Média dos testes (A, B, C)	17.33%	17.33%	29.33%

Tabela 1 - Resultados obtidos da percentagem de acerto com filtro de memória associativa e um classificador de uma camada

4.2 Perceptron + Classificador de uma camada

	Purelin	Hardlim	Logsig
Treino	47.35%	49.94%	49.29%
Teste A	42.00%	36.00%	42.00%
Teste B	32.00%	36.00%	48.00%
Teste C	42.00%	40.00%	46.00%
Média dos testes (A, B, C)	38.67%	37.33%	**45.33%**

Tabela 2 - Resultados obtidos da percentagem de acerto com filtro de *perceptron* e um classificador de uma camada

4.3 Classificador de uma camada

	Purelin	Hardlim	Logsig
Treino	84.82%	90.00%	86.53%
Teste A	80.00%	86.00%	82.00%
Teste B	88.00%	78.00%	82.00%
Teste C	92.00%	90.00%	90.00%
Média dos testes (A, B, C)	**86.67%**	84.67%	84.67%

Tabela 3 - Resultados obtidos da percentagem de acerto com classificadores de uma camada.

4.4 Classificador + softmax

	Purelin	Logsig
Treino	87.82%	84.24%
Teste A	90.00%	86.00%
Teste B	90.00%	78.00%
Teste C	88.00%	86.00%
Média dos testes (A, B, C)	**89.33%**	83.33%

Tabela 4: Resultados obtidos da percentagem de acerto com classificadores de duas camadas, sendo o segundo sempre o "*softmax*".

1290 FACULDADE DE CIÊNCIAS E TECNOLOGIA UNIVERSIDADE D COIMBRA

4.5 Classificador com 2 camadas

	Purelin e Purelin	Purelin e Logsig	Logsig e Purelin	Logsig e Logsig
Treino	86.12%	86.94%	87.00%	85.24%
Teste A	84.00%	80.00%	86.00%	74.00%
Teste B	88.00%	84.00%	88.00%	72.00%
Teste C	88.00%	88.00%	88.00%	82.00%
Média dos testes (A, B, C)	86.67%	84.00%	**87.33%**	76.00%

Tabela 5 - Resultados obtidos da percentagem de acerto com classificadores de duas camadas.

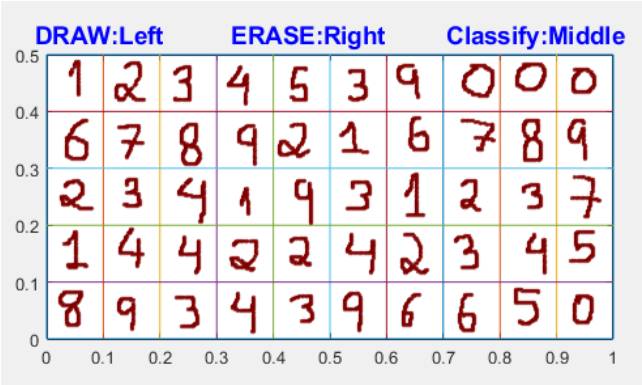

Figura 4 – Exemplo de um input para classificação

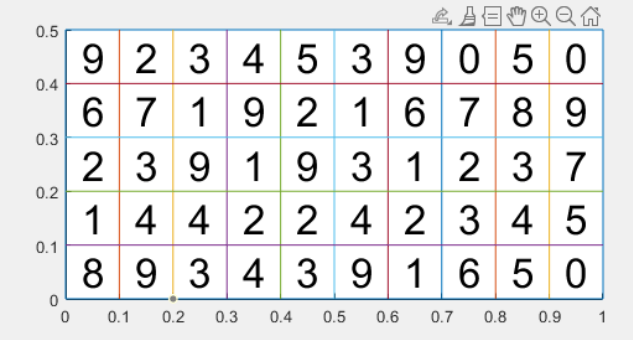

Figura 5 – Resultado da classificação com o modelo *Hardlim* de uma camada, sem filtro

5. Guia de Utilização da Aplicação

Para utilizar a aplicação entre na pasta disponibilizada por nosso grupo e abra o programa "app_OCR". Ao abrir este programa a seguinte janela deve abrir:

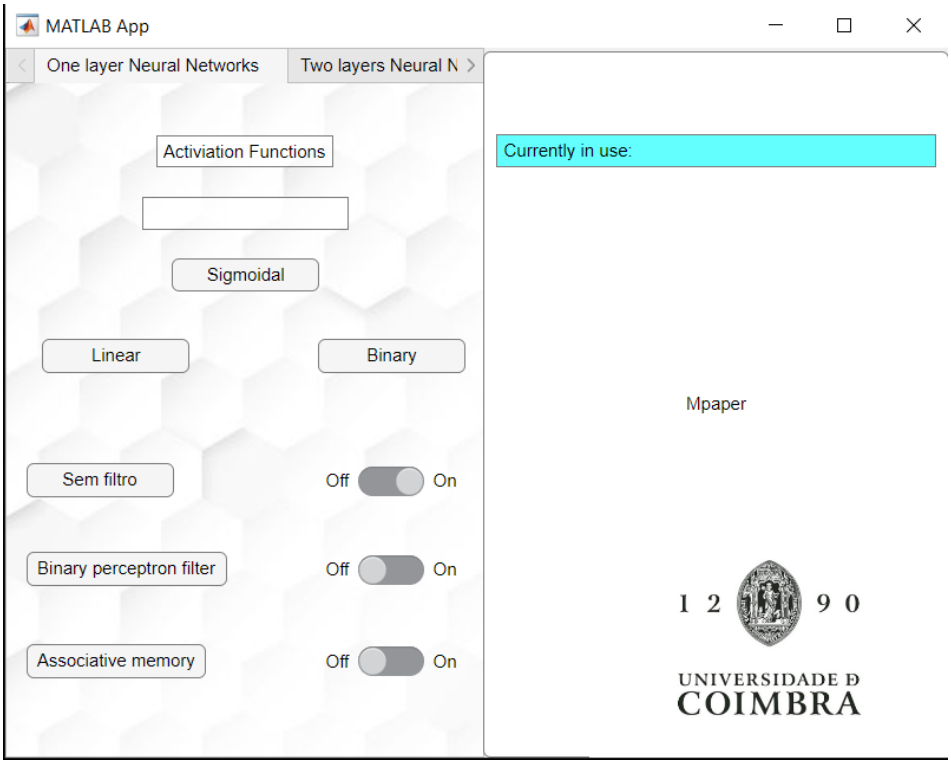

Nesta primeira aba chamada "*One layer Neural Networks*", o utilizador pode selecionar qual função de ativação e o filtro que gostaria de utilizar (note que os modelos foram treinados previamente e a aplicação foi feita apenas para testá-los). Ao selecionar uma das funções de ativação as duas caixas de textos presente na imagem devem mudar, como tal:

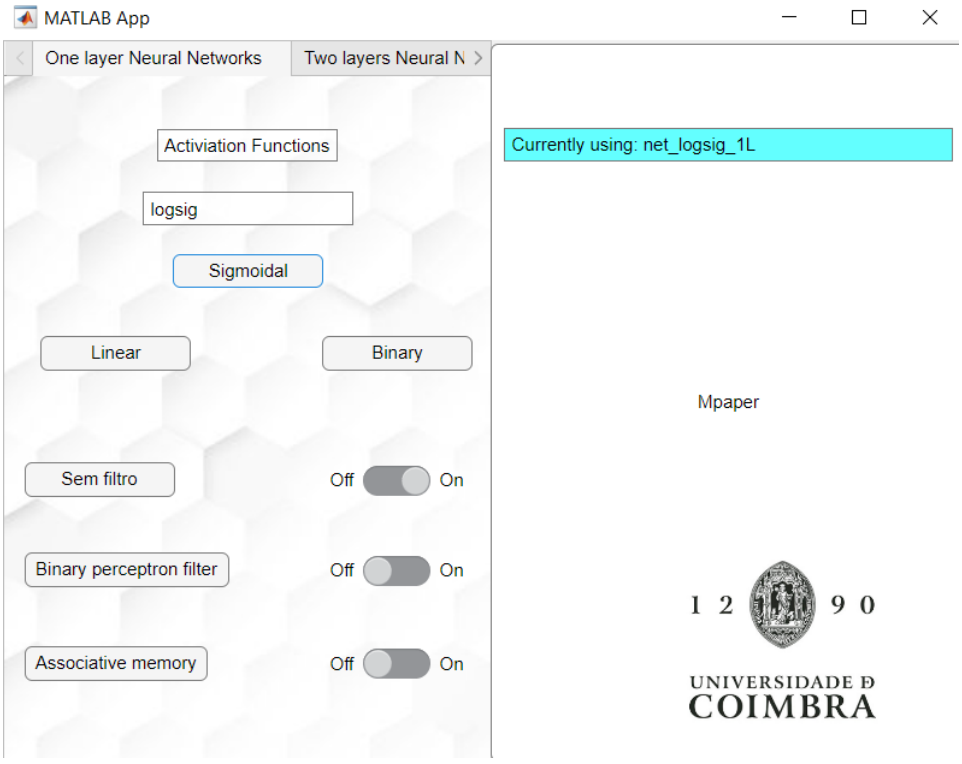

Como pode-se ver pela imagem a função sem filtro esta ligada, para utilizar outra basta ligar um dos outros dois interruptores.

Apos selecionar a função de ativação e o filtro basta clicar no "*Mpaper*", o que fazer apos isso será explicado na secção "*Mpaper*".

Na segunda aba o utilizador possui a seguinte visualização:

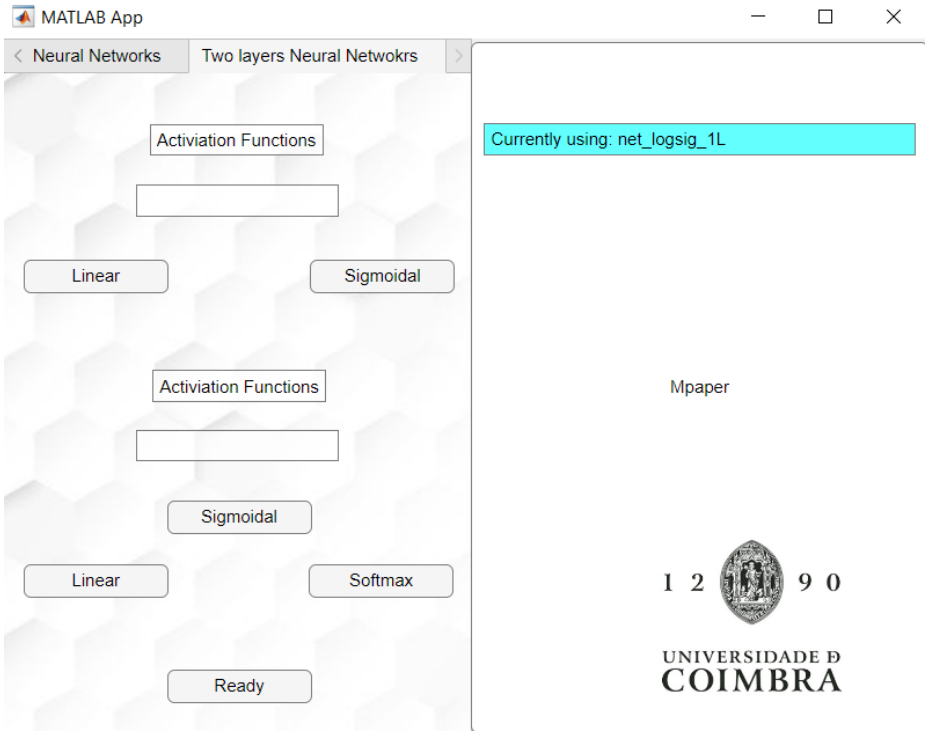

Neste caso deve-se selecionar duas funções de ativação e clicar no botão "Ready". Isso resultara em algo parecido a:

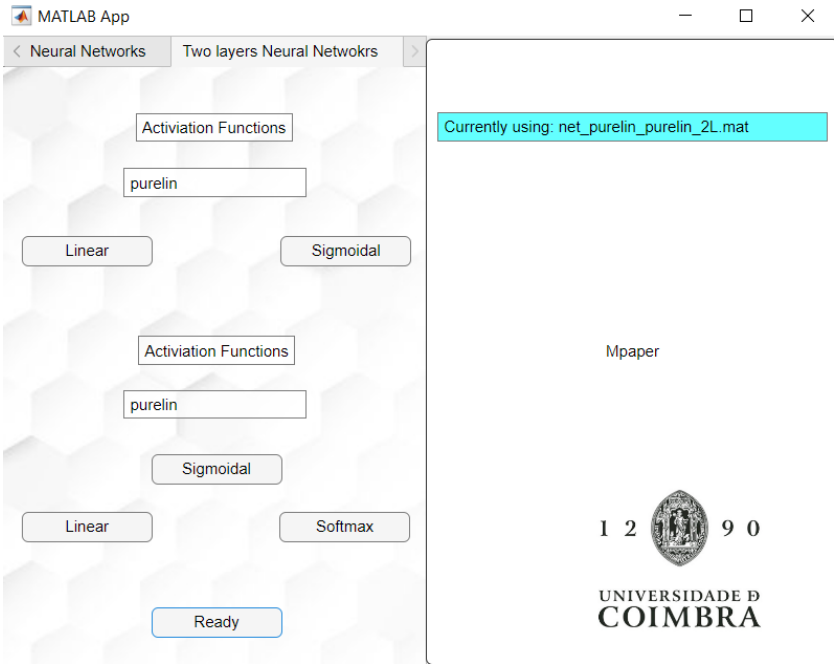

Note que em ambos o caso a caixa de texto azul possui o nome do modelo a ser utilizado.

Mpaper:

Apos clicar em “Mpaper” a seguinte janela deve aparecer para o utilizador:

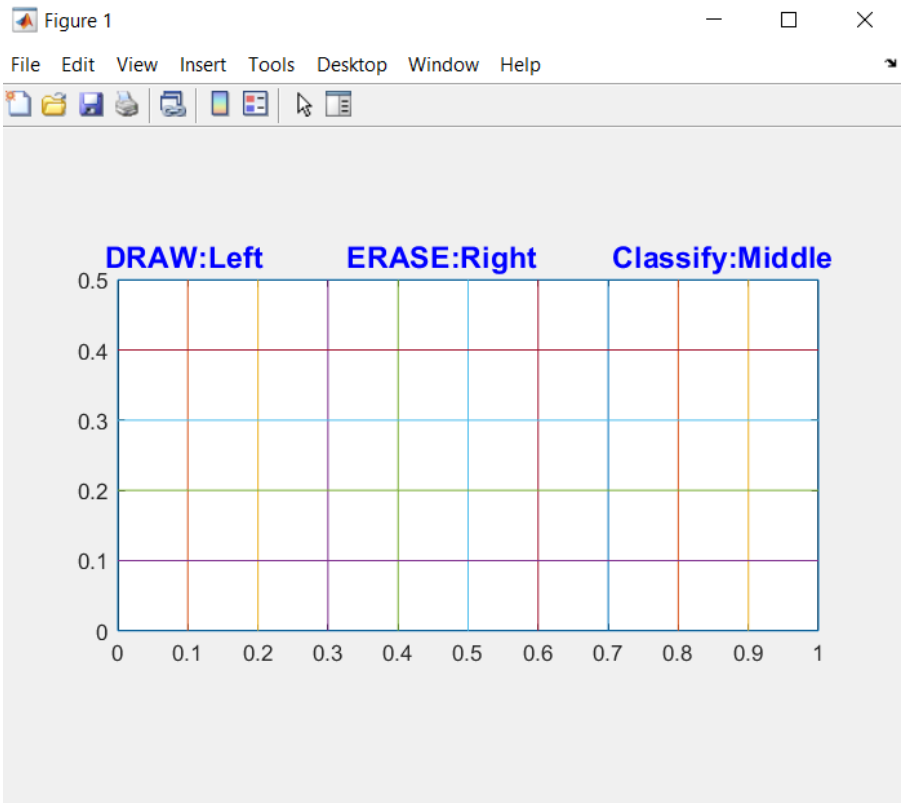

Neste caso o utilizador deve desenhar pelo menos um número e no máximo 50 números, um em cada um dos pequenos quadrados. Para tal basta utilizar o botão esquerdo do rato. O utilizador pode também apagar um dos números desenhados com o botão direito do rato (note que ao utilizar o botão direto do rato todo o desenho feito em um único quadrado eh inteiramente apagado).

Apos ter feito os desenhos que deseja o utilizador precisara apenas pressionar o botão do meio do mouse para utilizar o modelo selecionado na app. Apos pressionado duas janelas irão aparecer, a primeira com os números que o modelo adivinhou a segunda com uma representação do modelo selecionado.

Caso queria testar outro modelo não eh necessário seguir todo o procedimento de novo. Para utilizar outro modelo volte a aplicação, selecione o modelo que gostaria de utilizar, volte a onde foi desenhado os números e pressione o botão de meio novamente.

Nota 1: Caso não possua o botão do meio do rato basta pressionar Shift + botão esquerdo do rato.

Nota 2: Não eh possível utilizar filtros na rede neuronal de duas camadas, a aplicação tem proteções contra tal acontecimento.

Nota 3: A aplicação não possui suporte para tela cheia, sendo seu uso eh contraindicado.

6. Conclusão

Com este projeto e ao observarmos os resultados na secção 4 deste relatório, os modelos que obtiveram a maior taxa de acerto nos testes efetuados foram:

- Linear de uma única camada; (86.67%)
- Linear + softmax de duas camadas; (89.33%)
- Sigmoidal + linear de duas camadas; (87.33%)

Nestes três modelos, conseguimos observar que a média de acerto dos testes é superior ao acerto do treino. O que indica que muito provávelmente não houve *over-fitting* durante o mesmo. Mas existem casos em que observamos completamente o contrário, por exemplo no caso do classificador *hardlim* com uma camada, a taxa de acerto do treino é 90% e a média dos testes é 84.67%.

Os modelos apresentados acima também conseguiram identificar alguns números que foram desenhados de forma incorreta, porem não o suficiente para possuir relevância neste relatório, já que, frequentemente o algoritmo não conseguia identificar esses números, mostrando que no algoritmo feito há falhas caso os números saiam muito fora do padrão (por exemplo, um 3 invertido).

A resolução do problema apresentado acima não será apresentada neste relatório. Porém, a falha pode ser exposta pelo seguinte caso: o *dataset* utilizado neste relatório não foi robusto o suficiente para que o algoritmo consiga identificar números que não estejam na forma padrão.

É de notar que os classificadores com filtro, não obtiveram grandes resultados em comparação aos classificadores sem filtro

Portanto, o objetivo inicial do trabalho foi alcançado. Foi possível criar diversos modelos capazes de reconhecer, até certo ponto, algarismos desenhados a mão por seres humanos.

1 2 9 0
FACULDADE DE CIÊNCIAS E TECNOLOGIA
UNIVERSIDADE D COIMBRA